ArenaLabs ALPHAMOTION RESEARCH

MECHANISM AUDIT / 01

Spatial–Temporal 机制与潜空间审计

从源码计算图，到离散潜空间中的信息流

当前系统不是 Spatial hidden state 的时间演化。
它是六关键关节轨迹 codec，与冻结全身姿态补全器的串联系统。

Frozen checkpoints: E19 Spatial / V7-JEPA / V7-MaskFSQ

~~Read-only statistical probes~~ • ~~No retraining~~ • No architecture selection

审计摘要

一句话结论

模型已经学到结构化的运动潜空间，但当前系统验证的是**完整窗口压缩与运动学补全**，还不是因果未来预测，也不是闭环物理控制。

真实计算图

Temporal 直接读取 6 个关键关节的 9D 时序。Spatial E19 仅在 Temporal 输出后逐帧补全全身，不参与 Temporal 反向传播。

两种时间几何

JEPA 是无固定时间槽位的全局分布式表示；MaskFSQ 有对角时间结构，但组间 Transformer 让最终 code 仍然全局混合。

量化的选择性损失

连续 JEPA time feature 可用 89.7% 准确率读取动作速率；FSQ 后只剩 23.1%，接近 20% 随机水平。

证据边界

当前表示不含 world translation、contact、IMU、torque 或 WBC。运动学重建不能被写成 physically solid control。

62.69 bit/s
两条 Temporal 的匹配名义码率

1,494
无重复验证窗口

376 clips
clip-balanced 统计单位

3
checkpoints / 全部只读分析

本报告如何阅读

代码事实回答模型实际做了什么；**统计证据**回答 latent 中可读出什么；**因果干预**回答 decoder 是否真的使用这些信息。任何超出这三层证据的表述，均在报告中标为尚未证明。

1 当前真实系统，而不是概念图

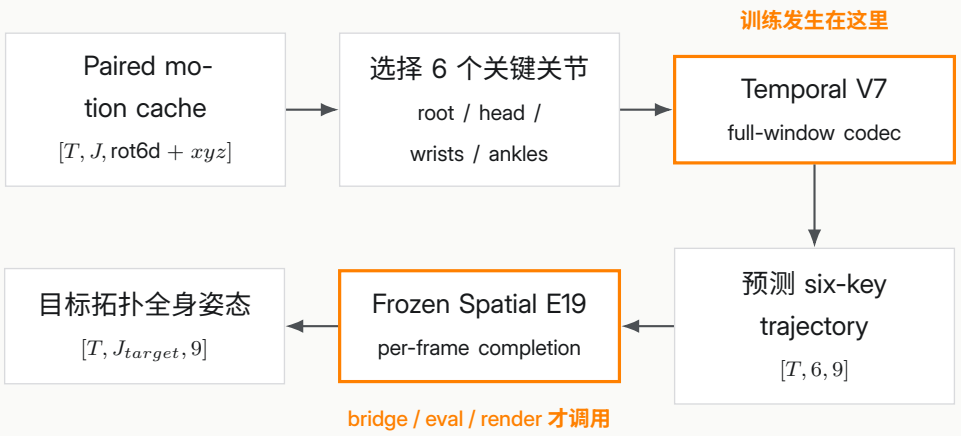


图 1: 当前 V7 的真实串联方式。Spatial checkpoint 出现在配置中，但没有进入 Temporal forward。

最重要的认知纠正

不能把 Temporal latent 称为“Spatial hidden state 的时间演化”。更准确的工程定义是：**Temporal 是关键关节轨迹 codec，Spatial 是独立训练的全身姿态流形 prior。**

1.1 源码证据

位置	事实
`train_v7.py L615--620`	训练只构造 KeyData 和 six-key window。
`train_v7.py L623--629`	`frozen_spatial` 只写入 config。
`train_v7.py L678--701`	Temporal forward 直接消费完整 key trajectory。
`v5_common.py L787--814`	先预测 six-key，再 mask 其他关节，经 E19 编解码。
`v7_bridge_mesh.py L75--86`	full-body completion 发生在 bridge。

2 Spatial：共享动作流形，仍保留身体签名

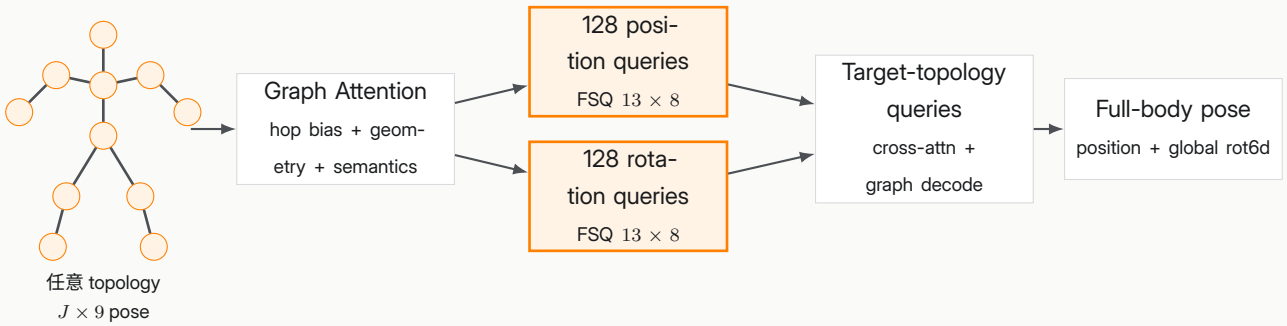


图 2: E19 Spatial 的双流离散瓶颈。mask 只隐藏 pose embedding，拓扑几何和关节语义仍然可见。

跨身体流形一致性

0.948

combined latent 的跨身体平均 off-diagonal CKA

身体仍可被读取

75.5%

body probe balanced accuracy，随机水平 20%

检查	Position stream	Rotation stream	两流合并
跨身体平均 CKA	0.808	0.961	0.948
身体分类 balanced accuracy	66.6%	88.6%	75.5%
随机水平	20.0%	20.0%	20.0%

大白话解释

Spatial 没有把“身体是谁”完全洗掉。它学到的是一个大体共享的动作坐标系，同时在其中留下可线性读取的身体签名。E19 同时接受跨身体 InfoNCE 和带梯度的 embodiment judge，这个结果与训练目标一致。

3 六关键点补全：旋转稳，位置是瓶颈

Full-pose code vs six-key masked code	Position	Rotation	合并
CKA	0.862	**0.993**	0.981
样本余弦中位数	0.521	**0.912**	0.690
FSQ scalar 完全一致率	35.1%	**58.8%**	46.9%

群体几何仍然相似

高 CKA 表示样本间的关系结构被保留，不代表同一帧落在相同离散 token。

单样本 token 大量改写

位置流 exact agreement 仅 35.1%，六点约束进入全身补全时主要损失位置细节。

11.13 cm
隐藏关节平均位置误差

24.95°
隐藏关节平均旋转误差

14.94 cm
可见六关节平均位置误差

22.24°
可见六关节平均旋转误差

为什么可见关节也有误差

E19 的 `vis_residual=False`。可见关节不会直接复制，而要与隐藏关节一样穿过 FSQ 瓶颈后重新生成。E28 有同骨架 residual copy，但当前 V7 bridge 固定使用 E19。

4 Temporal 公共骨架：先验轨迹上的残差 codec

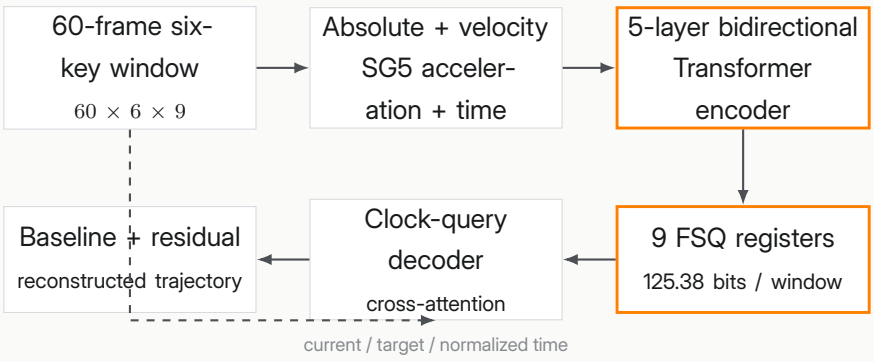


图 3: 两条 Temporal arm 共享 frame encoder 和 residual decoder 的总体形式。

当前验证的是 codec，不是 predictor

训练随机选择后半段目标帧 k，但 encoder 仍然看到完整窗口，包括 k 后的帧；decoder 还显式获得 current、target、k_{norm} 和输出长度。因此当前学习的是

$$P(\text{discrete motion representation} \mid \text{complete window, endpoints}),$$

而不是 $P(\text{future} \mid \text{observed prefix, intent})$。

Residual prior

两条 arm 都以 current 到 target 的直线插值作为结构先验，网络只预测偏离该直线的 residual。endpoint-only regression 已能解释运动摘要的中位 $R^2 = 0.174$；latent 的价值必须以“超出 endpoint 的增量”衡量。

5 两条 Temporal arm 学到不同的时间几何

JEPA / 8 path + 1 time

- 8 个 learned queries 全局读取 frame 与 endpoint context。
- path registers 无固定时间槽位，是分布式全局表征。
- 单独的 time register 读取累计弧长曲线、总路程、帧数比例和平均速度。
- JEPA loss 是同 encoder 的 stop-gradient latent reconstruction，并非经典 I-JEPA target encoder。

MaskFSQ / 9 temporal groups

- warmup 后对 frame token 做 rand / sparse / prefix masking。
- 60 帧先分成 9 个固定连续组，并在组内 attention pooling。
- 9 个 group token 随后进入 2 层全局 Transformer。
- 最终 code 是“时间锚定、全局上下文化”，并非互相独立的局部片段。

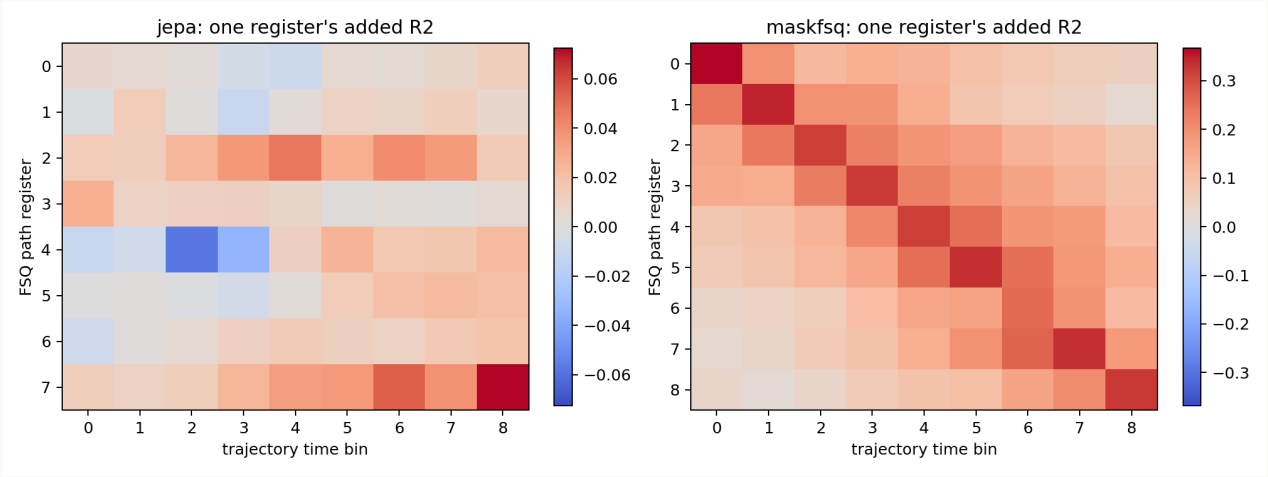


图 4: 单个 register 对 9 个轨迹时间段的增量 R^2。MaskFSQ 显示明显对角带，同时存在跨时间信息扩散。

0.016	0.011	0.325	0.135
JEPA diagonal added R^2	JEPA off-diagonal	MaskFSQ diagonal	MaskFSQ off-diagonal

6 JEPA 的 time register 不是“时长 token”

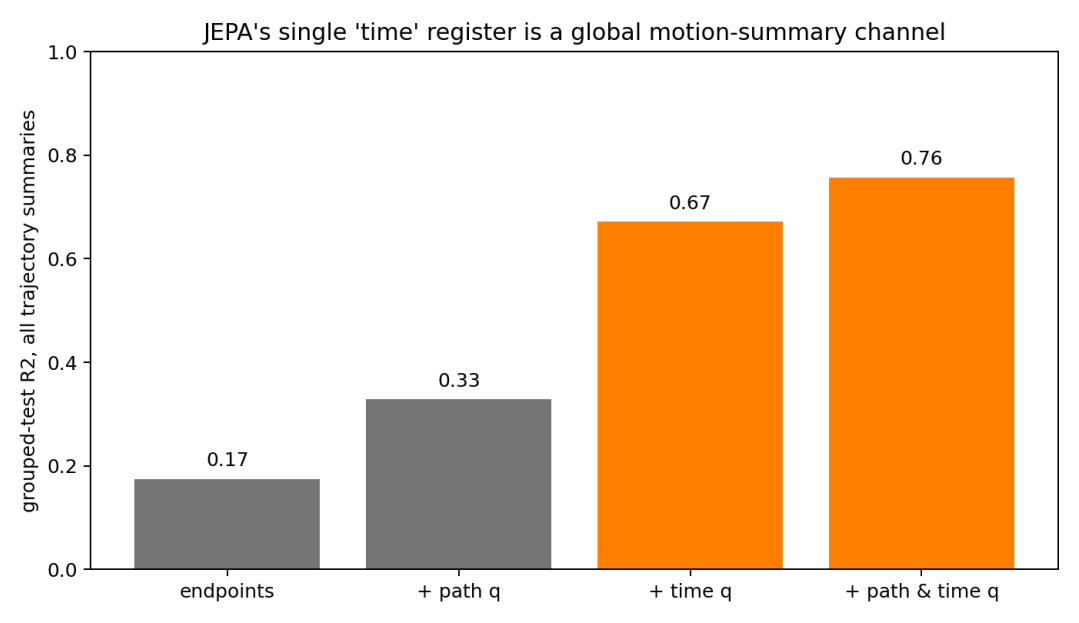


图 5: Grouped ridge 对 33 个轨迹摘要的解释度。time register 本身已经携带大量全局运动信息。

输入到 linear probe	轨迹摘要中位 R^2
Endpoints only	0.174
Path quantized only	0.190
Endpoints + path quantized	0.328
Time quantized only	0.631
Endpoints + time quantized	0.671
Endpoints + all quantized latents	0.757
Endpoints + all continuous latents	0.780

机制解释

time register 是一条**粗粒度全局运动摘要通道**。它概括路径进度和运动能量；path bank 则承担无法被这些摘要覆盖的动作细节。两者不是严格的“内容 / 时长”二分。

7 相关性之外：decoder 真的使用这些 latent

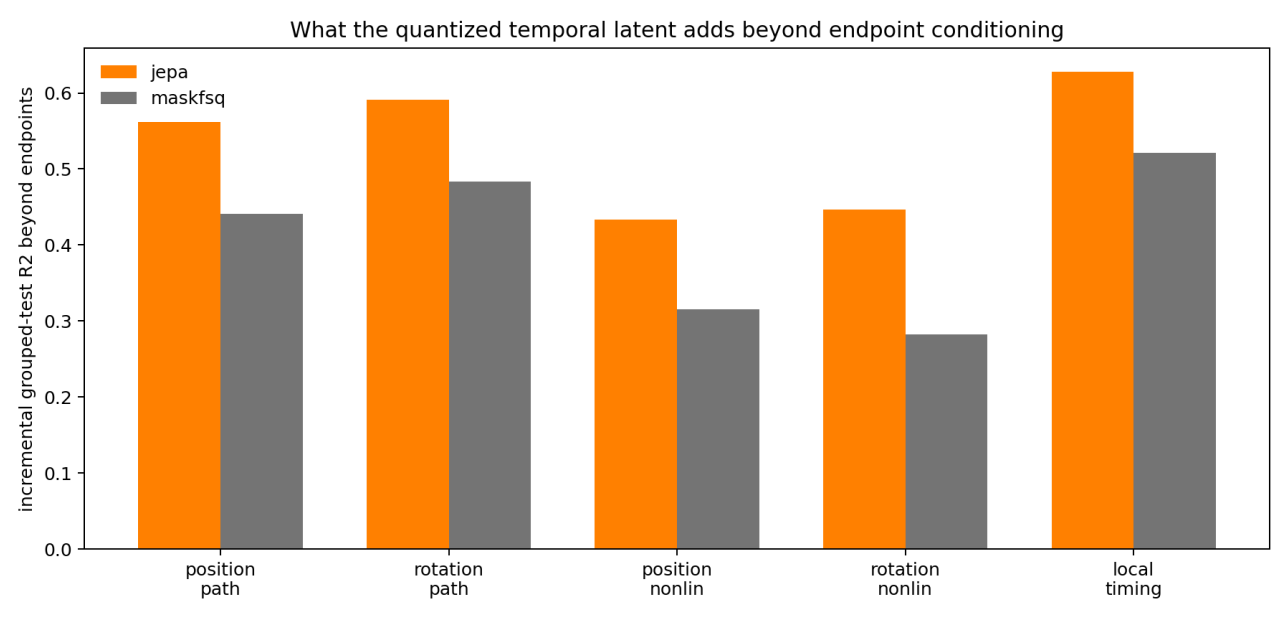


图 6: 量化 latent 在 endpoint conditioning 之外增加的 grouped-test R^2。

模型	因果干预	位置误差	相对正确 code
JEPA	正确 code	6.743 cm	–
JEPA	跨样本打乱 path	11.847 cm	+5.117 cm
JEPA	跨样本打乱 time	8.598 cm	+1.856 cm
MaskFSQ	正确 code	6.395 cm	–
MaskFSQ	跨样本打乱 path	15.315 cm	+8.925 cm

为什么 shuffle 比 zero 更可信

跨样本 shuffle 保持 code 在训练分布内，只破坏它与当前动作的对应关系。zero code 属于分布外干预，适合作为 stress test，但不能单独用于解释功能。

8 最明确的量化边界：速率方向被 FSQ 抹掉

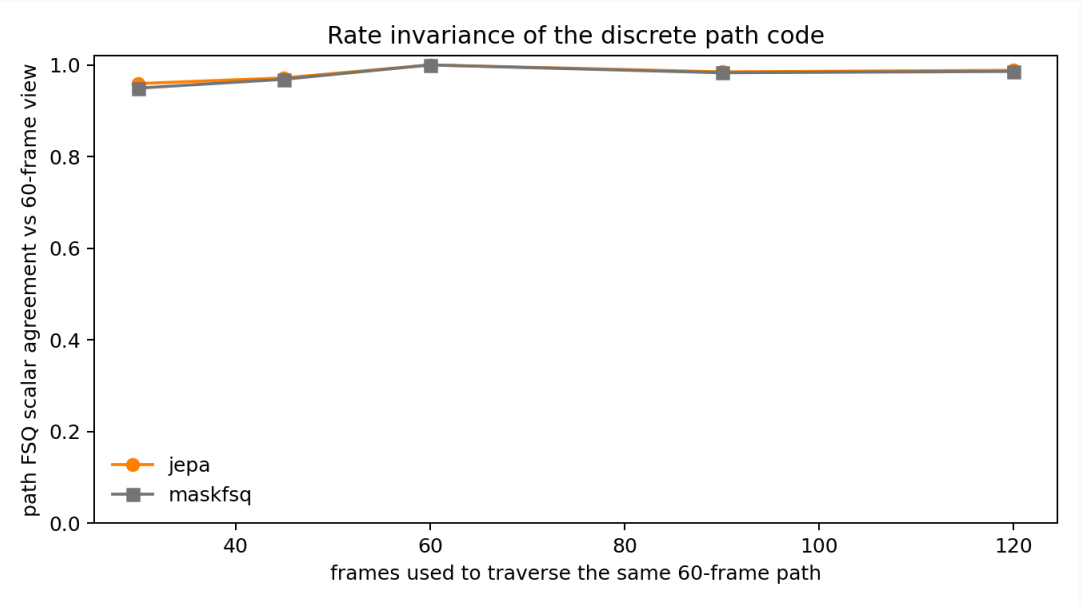


图 7: 同一路径以 30/45/60/90/120 帧通过时，离散 path code 保持高度一致。

JEPA time feature **中的速率可读性**

89.7%
continuous f

→

23.1%
quantized q / chance 20%

这不是上游没学到

连续 time pathway 中存在清晰的线性速率方向；经过当前 6 维、5-level FSQ rounding 后几乎不可读。量化损失是**方向选择性的**，并非统一降低一点精度。

9 同样本重建差异：可信，但不能直接归因

指标	JEPA	MaskFSQ	Mask − JEPA，95% CI
位置误差	6.743 cm	6.395 cm	$-0.358\ [-0.432, -0.286]$ cm
旋转误差	10.647°	9.840°	$-0.811\ [-0.943, -0.684]°$
运动能量保持	0.899	0.939	$+0.039\ [+0.032, +0.046]$

不要把这张表写成架构胜负

两条 arm 不只改变 token geometry。它们同时改变 frame masking、JEPA loss、time register、encoder endpoint context 和 invariance augmentation。匹配 62.69 bit/s 只消除了码率差异，没有形成单变量实验。

9.1 FSQ 使用情况

Code bank	标量独立熵之和	名义容量
JEPA path	96.00 bits	111.45 bits
JEPA time	9.67 bits	13.93 bits
MaskFSQ path	123.72 bits	125.38 bits

标量熵求和忽略维度依赖，是 joint entropy 的上界，不能直接当作真实压缩率。

10 跨骨架与数据支撑度

Embodiment identity probe

Endpoint only	93.1%
JEPA path latent	25.3%
MaskFSQ path latent	22.9%
Chance	20.0%

解释

Temporal cross-body InfoNCE 显著压低了身体身份，但没有完全消除。机器人间 CKA 高于 human-to-robot，部分来源是它们共享同一 re-targeting pipeline，不能单独当作自然跨形态泛化证据。

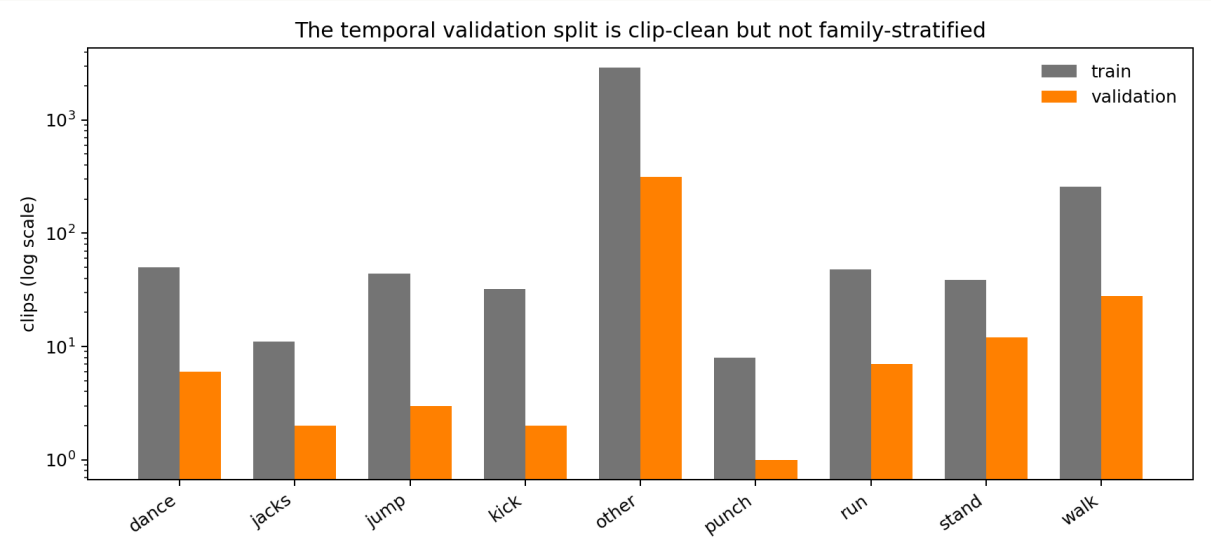


图 8: Temporal clip-level split 的动作族支撑。验证集未按 family 分层，稀有动作的结论不稳定。

评估协议的三处风险

1. Spatial 旧评估使用 frame-level random split，相邻帧可能跨 train / val；本文 Spatial probe 改用 AMASS，避免直接复用该 split。
2. Temporal 是 clip-clean split，但 punch 仅 1 个 val clip，kick 和 jacks 各 2 个，jump 3 个。
3. family probe 只说明训练分布中存在可线性读取的类别结构，不是组合泛化或 OOD 理解证据。

11 证据边界：现在可以说什么

已有证据支持

- Spatial 形成共享但带身体签名的姿态流形。
- Temporal 以约 62.69 bit/s 保留路径、非线性和局部时序信息。
- JEPA 是全局分布式表示；MaskFSQ 是时间锚定、全局上下文化表示。
- FSQ 对不同信息方向有选择性损失。
- latent 对 decoder 输出具有因果作用。

目前不能宣称

- Spatial hidden state 被 Temporal 直接建模。
- Temporal 已能只看过去生成未来。
- JEPA 或 MaskFSQ 已经胜出。
- token 具有固定的人类可读动作语义。
- 系统已学到 contact-aware、physics-solid 闭环控制。

物理边界

默认 `root_vel=False`；位置均为 root-relative。当前输入和损失中没有 world translation、contact、IMU、torque 或 actuator state。现有数字衡量的是运动表示与运动学重建，不是 WBC 的稳定性、柔顺性和抗扰恢复。

12 下一轮最小可归因实验矩阵

编号	控制变量	要回答的问题
01	固定 token geometry，只开/关 frame masking	局部结构收益来自 token 位置，还是来自遮挡训练?
02	固定 token geometry，只开/关 JEPA loss	stop-gradient target 是否真正改变表示几何?
03	固定 encoder context，只开/关 time register	全局摘要通道是否必要，是否挤占 path capacity?
04	两条 arm 使用相同 invariance augmentation	当前 warp / uniform 差异贡献多少?
05	prefix-only causal encoder，移除 acausal SG 特征	模型是否能从已观测历史预测未见未来?
06	family-stratified clip split	稀有动作结果是否可复现?
07	分开测 Temporal six-key 与 Spatial completion error	两层分别贡献多少误差?
08	加入 world root、contact、IMU 与 WBC rollout	表示质量是否转化为真实物理执行能力?

研究原则 先构造可归因的反事实，再讨论架构选型；先区分运动学、动力学与控制，再讨论“physical intelligence”。

附录：可复现资产与方法

资产	路径 / 方法
完整机器可读结果	`pose_translator_design/audits/DEEP_AUDIT_0807/audit.json`
审计脚本	`pose_translator_design/exp_topo/audit_spatiotemporal_latent.py`
Temporal 抽样	1,494 unique windows / 376 validation clips / max 4 windows per clip
回归	clip-grouped Ridge；报告 grouped-test median R^2
区间估计	paired clip bootstrap，95% interval
因果干预	in-distribution cross-sample latent shuffle；zero code 仅作 OOD stress test
Spatial probe	240 AMASS frames / 5 embodiments；独立于 E19 的 LAFAN frame split
模型状态	checkpoints read-only；无参数更新，无重新训练

审计对象

`E19_K128_0805` / `V7_jepa_0807` / `V7_maskfsq_0807`

ArenaLabs

Physical AI Research